Анализ факторов, влияющих на страховые выплаты

Автор: Зотова Дарья

Содержание

01 **Контекст**
Описание и цель проекта

02 **Методология**
Источники и объём данных, масштаб анализа

03 **Главные выводы**
Главные открытия анализа и доказательная база

04 **Рекомендации**
Конкретные шаги для бизнеса

Контекст

Описание и цель проекта

Контекст

Страховая компания предоставила данные о застрахованных и их медицинских расходах, чтобы понять, как пол, регион проживания и индекса массы тела отражаются на размере страховых выплат.

Цель проекта: проанализировать данные, выявить статистически значимые зависимости этих факторов и определить, какие из них важно учитывать компании при оценке рисков и прогнозировании расходов.

Методология

Источники и объём данных, масштаб анализа

Методология

Анализ выполнен на датасете из 1338 записей о застрахованных с данными о возрасте, поле, индексе массы тела, числе детей, курении и регионе проживания. Пропусков и неопределённых значений нет.

В ходе анализа выполнены следующие шаги:

1. Предобработка: оптимизация числовых признаков, проверка дубликатов.
2. Исследовательский анализ распределений, выбросов и структуры признаков.
3. Проверка гипотез о влиянии пола, региона и BMI на страховые выплаты.

Главные выводы

Главные открытия анализа и доказательная база

Типичный уровень выплат у мужчин и женщин сопоставим

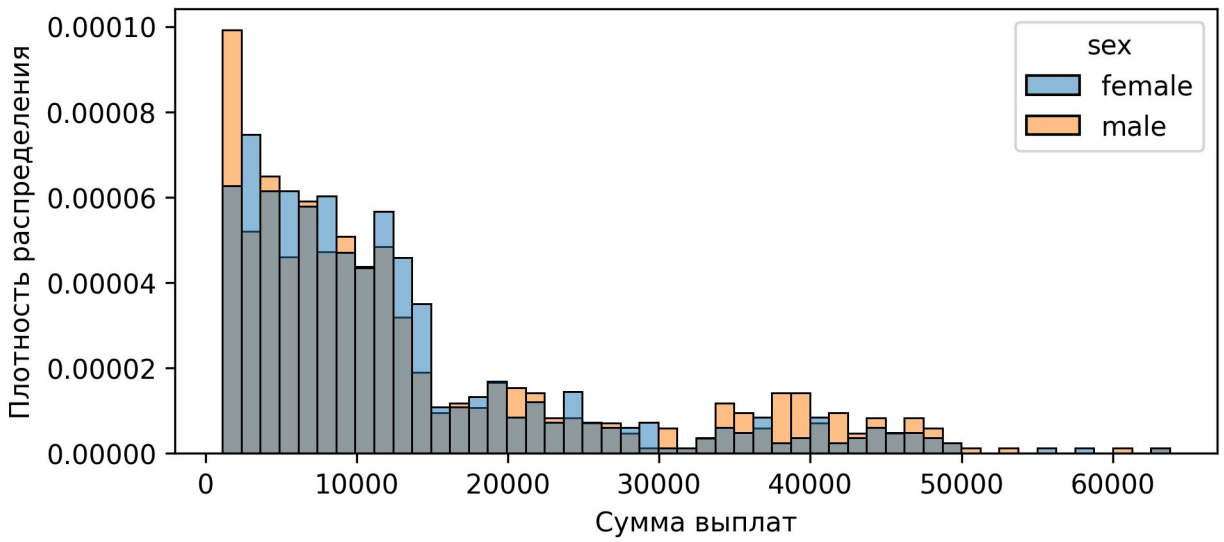

Средние выплаты:
мужчины (676 человек) — 13 957,
женщины (662 человека) — 12 570.

t-тест Уэлча:
p-value = 0.036 < 0.05 →
различие средних статистически значимо.

тест Манна–Уитни:
p-value = 0.73 > 0.05 →
различий в распределениях не выявлено.

По совокупности тестов можно сделать вывод, что различие средних страховых выплат между мужчинами и женщинами обусловлено редкими, но крупными выплатами у мужчин, а не систематически более высокими расходами в целом.

Обоснование выбора тестов: Приложение 1.

Регион проживания не является значимым фактором риска

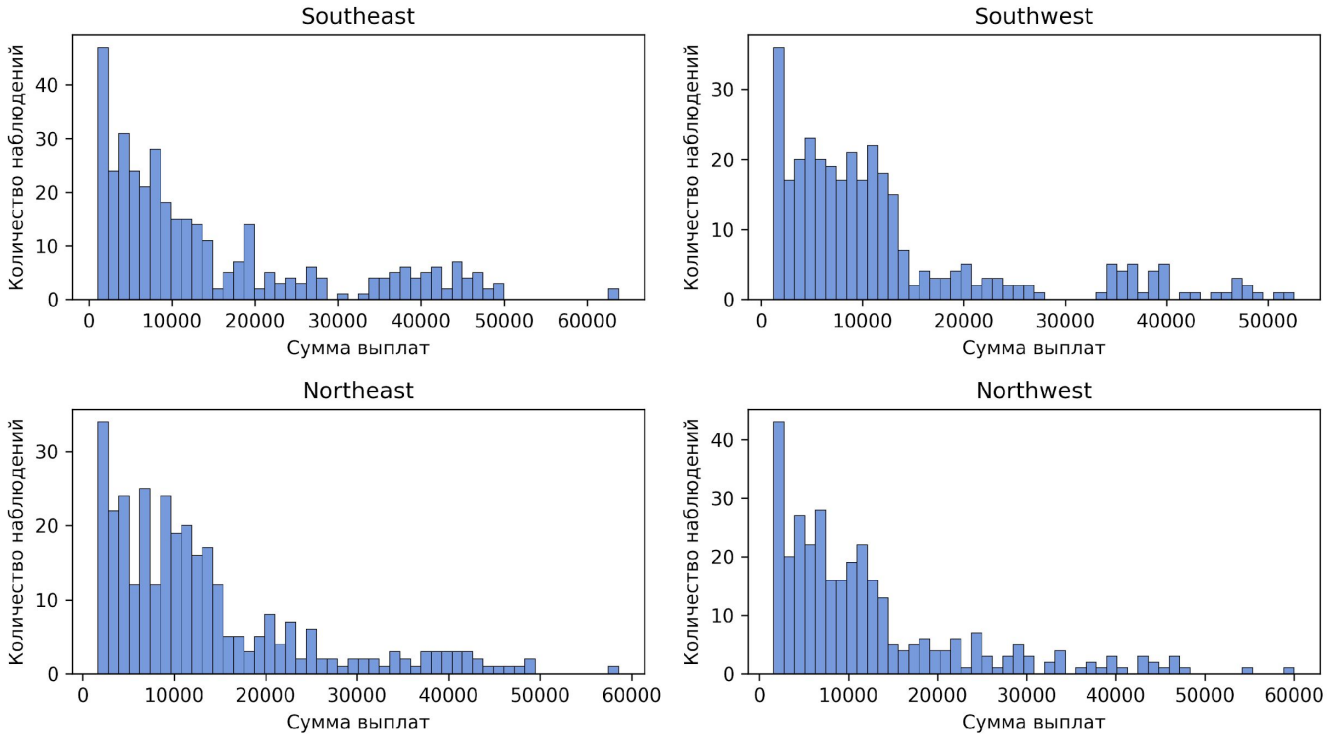

Средние выплаты:
Southeast (364 человека) — 14 735,
Southwest (325 человек) — 12 347,
Northeast (324 человека) — 13 406,
Northwest (325 человек) — 12 418.

ANOVA Уэлча:
p-value = 0.051 > 0.05 →
пограничное значение.

Краскел–Уоллис:
p-value = 0.19 > 0.05 →
значимых различий не выявлено.

По совокупности тестов можно сделать вывод, что статистически значимых различий страховых выплат по регионам не выявлено.

Обоснование выбора тестов: Приложение 2.

Рост BMI увеличивает вероятность крупных расходов

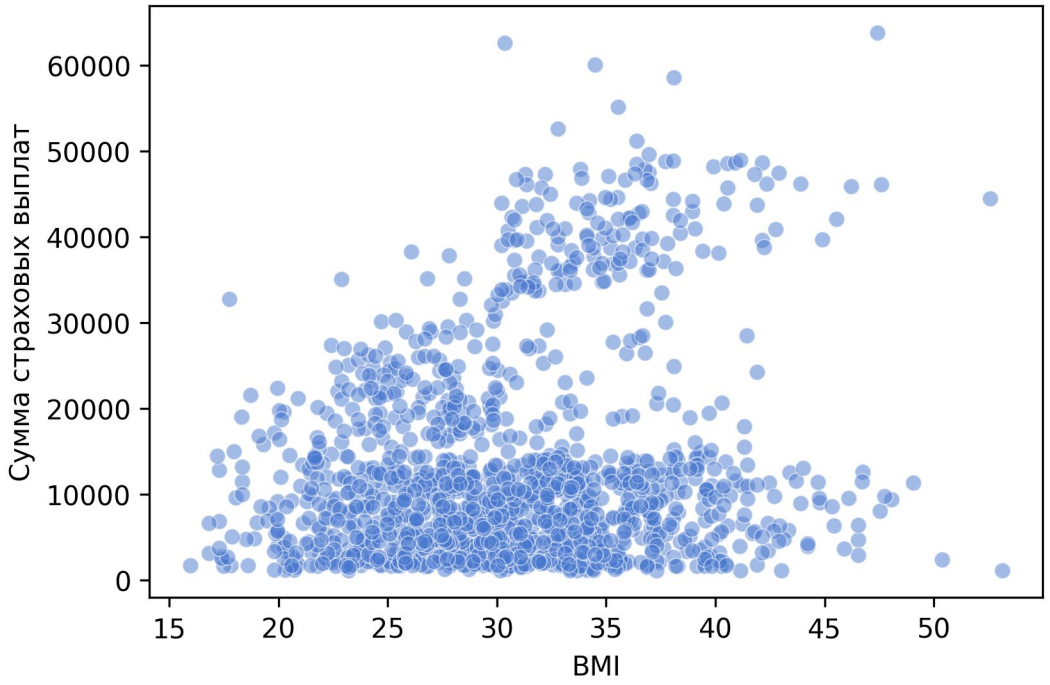

График показывает:
линейной зависимости нет, но при BMI > 30 чаще встречаются крупные и более вариативные выплаты.

Коэффициент Спирмена:
$\rho = 0.119$, p-value < 0.001

По совокупности исследований можно сделать вывод, что индекс массы тела имеет слабую, но статистически значимую положительную связь со страховыми выплатами. Рост BMI увеличивает вероятность крупных расходов, но не является определяющим фактором сам по себе.

Обоснование выбора методов: Приложение 3.

Рекомендации

Конкретные шаги для бизнеса

Рекомендации

1. Не использовать пол и регион как самостоятельные основания для повышения базовых страховых тарифов, поскольку их влияние на типичный уровень страховых выплат ограничено и не затрагивает основную массу клиентов.

2. Учитывать пол и BMI при оценке риска крупных страховых убытков, так как именно в правом хвосте распределения (редкие, но дорогостоящие случаи) у мужчин и у застрахованных с высоким BMI наблюдается повышенная вариативность и более высокие выплаты.

3. Применять многомерные модели оценки риска, в которых пол, BMI, возраст и поведенческие факторы (например, курение) рассматриваются совместно, а не изолированно.

4. В аналитике страховых выплат не ограничиваться сравнением средних значений. Дополнительно анализировать крупные и редкие страховые случаи: оценивать вероятность очень больших убытков и факторы, повышающие риск попадания в эту группу. Это позволит точнее рассчитывать страховые резервы и лучше контролировать совокупные расходы.

Приложения

Дополнительные данные и детали

Приложение 1.
Влияние пола на выплаты: обоснование тестов

Гипотезы:
- H0: Средние страховые выплаты у мужчин и женщин не отличаются.
- H1: Средние страховые выплаты у мужчин и женщин отличаются.

Предпосылки:
- Исходя из описания датасета и структуры данных, каждая строка интерпретируется как отдельный застрахованный. Поэтому в рамках анализа предпосылку о независимости наблюдений будем считать выполненной.
- Несмотря на отклонение распределений страховых выплат от нормального, объёмы выборок в группах достаточно велики (676 и 662 соответственно). В силу ЦПТ распределения выборочных средних можно считать приближённо нормальными.
- Распределения в группах похожи: в основном небольшие выплаты и редкие крупные, без заметных различий.
- Тест Левена показал статистически значимые различия дисперсий между полами ($p\text{-value} = 0.0017 < 0.05$). Следовательно, предпосылка равенства дисперсий нарушена.

Статистические тесты, выбранные исходя из предпосылок:
- t-тест Уэлча (основной): применяется для сравнения средних, требует независимости наблюдений и нормального распределения средних, устойчив к нарушению предпосылки равенства дисперсий.
- тест Манна-Уитни (дополнительный для проверки устойчивости вывода): сравнивает распределения, требует независимости выборок и схожих форм распределения, устойчив к разным дисперсиям и выбросам.

Приложение 2.
Влияние региона на выплаты: обоснование тестов

Гипотезы:

- H0: Средние страховые выплаты одинаковы во всех регионах.
- H1: Хотя бы в одном регионе средние страховые выплаты отличаются.

Предпосылки:

- Исходя из описания датасета и структуры данных, каждая строка интерпретируется как отдельный застрахованный. Поэтому в рамках анализа предпосылку о независимости наблюдений будем считать выполненной.
- Во всех регионах распределения страховых выплат имеют выраженную правостороннюю асимметрию с длинным хвостом редких крупных выплат (до 50–60 тыс.). Распределения не являются нормальными, что типично для страховых данных. Однако размеры групп достаточно велики (324-364), поэтому умеренное отклонение от нормальности не критично.
- Формы распределений во всех регионах в целом схожи: концентрация малых выплат и правый хвост крупных значений.
- Тест Левена показал статистически значимые различия дисперсий между регионами ($p\text{-value} = 0.00086 < 0.05$). Следовательно, предпосылка равенства дисперсий нарушена.

Статистические тесты, выбранные исходя из предпосылок:

- тест ANOVA Уэлча (основной): применяется для сравнения средних более чем в двух независимых группах, требует нормального распределения средних и устойчив к нарушению предпосылки равенства дисперсий.
- тест Краскела–Уоллиса (дополнительный для проверки устойчивости вывода): сравнивает распределения более чем в двух независимых группах, требует схожих формы распределения, устойчив к разным дисперсиям и выбросам.

Приложение 3.
Влияние BMI на выплаты: обоснование методов

Гипотезы:
- H0: Между BMI и страховыми выплатами нет значимой связи.
- H1: С ростом BMI страховые выплаты увеличиваются.

Предпосылки:
- Исходя из описания датасета и структуры данных, каждая строка интерпретируется как отдельный застрахованный. Поэтому в рамках анализа предпосылку о независимости наблюдений будем считать выполненной.
- Обе переменные (BMI и страховые выплаты) являются количественными.
- Распределение страховых выплат имеет правостороннюю асимметрию и выбросы.
- Исходная гипотеза предполагает монотонную, но не обязательно линейную связь между переменными.

Методы, выбранные исходя из предпосылок:
- Scatter plot: применяется для визуальной оценки направления и формы связи между количественными переменными.
- Корреляция Спирмена: применяется для оценки силы и направления монотонной связи между двумя количественными переменными при отсутствии предпосылок нормальности и линейности и при наличии выбросов.